
Cassandra Database

No-SQL




Jayne de Morais Silva
Programa de Pós-Graduação em Ciência da Computação (Mestrado)
Disciplina: Banco de Dados - Prof. Dr. Carlos Eduardo
Novembro, 2020

ÍNDICE

- I. Introdução
- II. Estrutura
- III. Demonstração
- IV. Vantagens e Desvantagens
- V. Aplicações Notáveis
- VI. Referências

I. INTRODUÇÃO



2008

Motor de Busca
Caixa de Entrada de Mensagens do Facebook

Open-Source

Código aberto que pode ser adaptado para diversos fins.



2009

Apache Foundation


*Licença Apache 2.0



ARQUITETURA



- Arquitetura **Distribuída e Descentralizada**
 - Modelo de **Distribuição do Sistema**




- Escalabilidade Horizontal

- Forma de **Organização dos Dados**



TEOREMA CAP



*É possível ter todas as três garantias no Cassandra, mas *não ao mesmo tempo*.

II. ESTRUTURA

MODELO DE DADOS

- **Tipo Colunar**
 - Estrutura agregada de duas camadas, onde existe um **identificador** de linha e um **mapa** com valores mais detalhado;
 - Dados **desnormalizados** e **amplamente consultados**;
 - **Linhas diferentes** na mesma tabela não precisam compartilhar o mesmo conjunto de **colunas**.

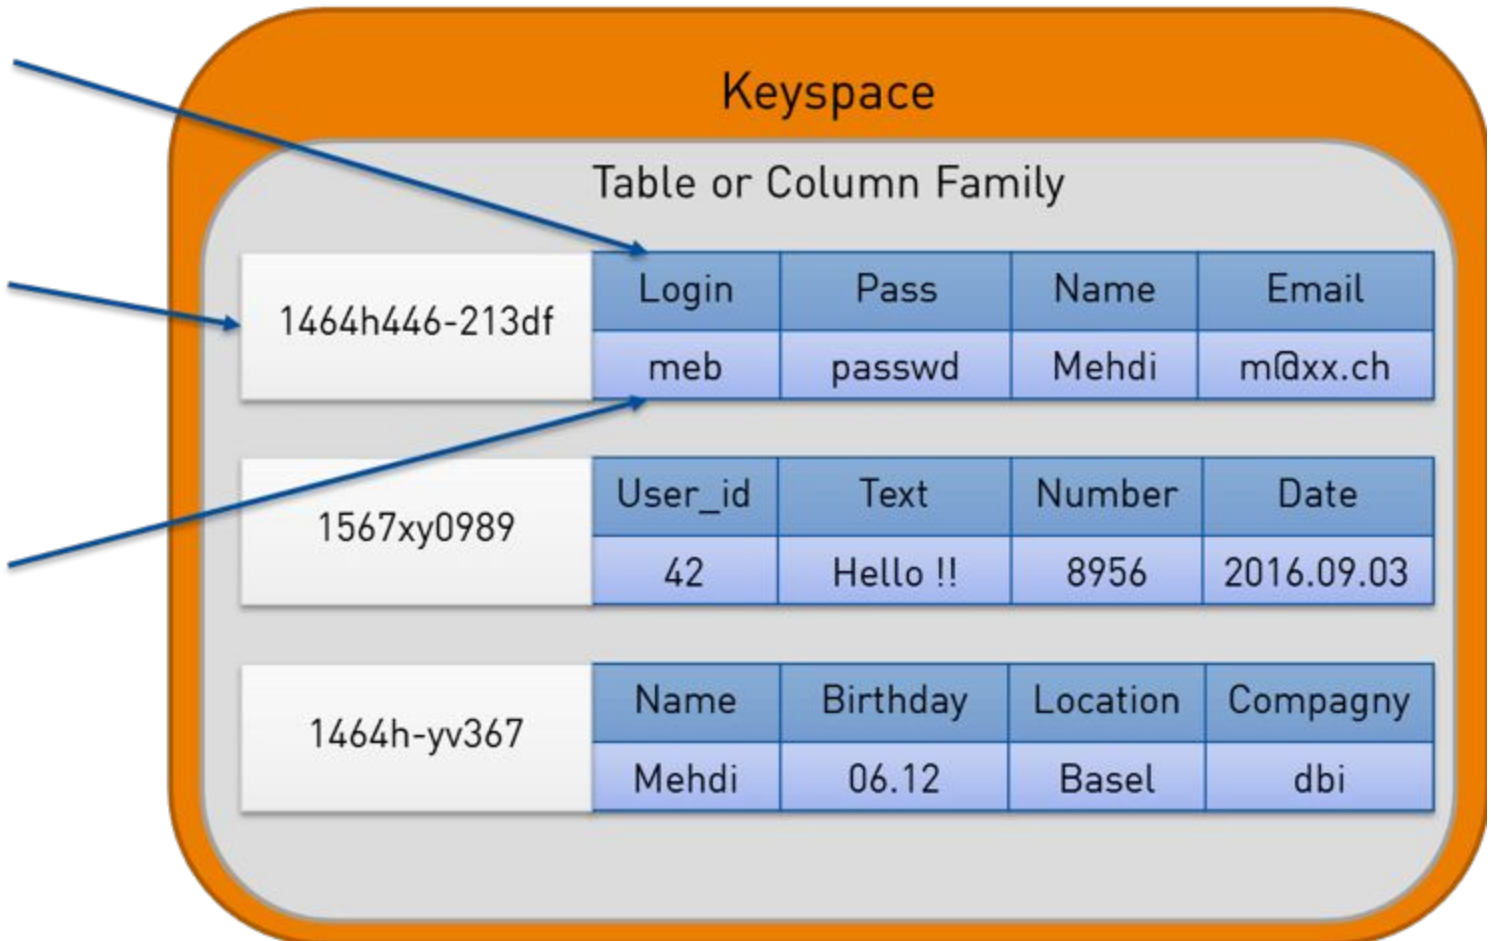
ESTRUTURA

- **Keyspace**: Conjunto de tabelas;
- **Famílias de Colunas**: Contêiner para um conjunto de linhas ;
- **Linhas**: Contém uma chave primária e **um conjunto de colunas relacionadas**;
- **Colunas**: representam um conjunto de **chave/valor**:
 - **Column key**: Nome da coluna;
 - **Column value**: É o valor que está sendo persistido;
 - **Timestamp**: Esse campo é utilizado para resolver conflitos e determinar qual é o valor mais atual.

Column
key

Row key

Column
value




FUNCIONAMENTO I

- Partition Key Table
- *Data Sharding*
 - Distribuição das partições entre nós do cluster e então **replicadas** em múltiplos nós;
 - Alta Disponibilidade e Tolerância a Falhas
- Em que nó do cluster cada partição será gravada?

ARQUITETURA EM ANEL

- Faixas (tokens) baseadas na Hash de chave
 - Inteiro de 64 bits (-2^{63} até $2^{63}-1$)



FUNCIONAMENTO II

- **Detecção** de nós com indícios de **falha**;
 - *Gossip Protocol.*
- **Atualização** de Dados e **Inserção** de Dados;

III. DEMONSTRAÇÃO

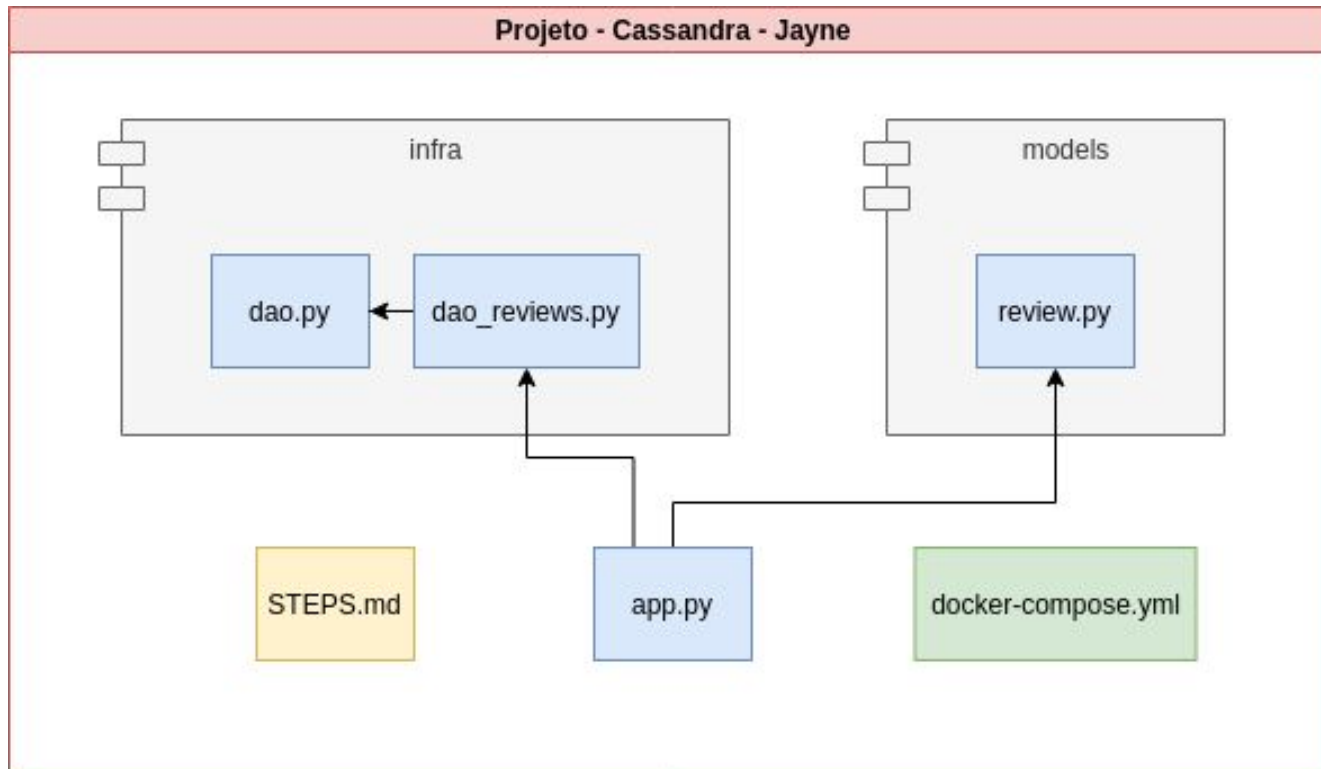
CASO DE USO

Reviews de usuários sobre Filmes

- *Objetivo e Justificativa: Utilização do banco NoSQL Cassandra para otimização sob as consulta sobre reviews, visto que existem muitos dados sobre reviews e os mesmos são utilizados para aplicações específicas, como em modelos de Ciência de Dados.*

*Caso de Uso Fictício

ARQUITETURA





Instalação e Configuração

- <https://github.com/JayneMorais/CassandraDatabase>
- *Cassandra Query Language*



KEYSPACE

```
22
23     def create_keyspace(self):
24
25         query = """
26             CREATE KEYSPACE IF NOT EXISTS reviews_db
27             WITH REPLICATION = {
28                 'class' : 'SimpleStrategy',
29                 'replication_factor' : 2
30             };
31         """
32         self.__session.execute(query)
33         self.__session.set_keyspace("reviews_db")
```

TABLE

```
38
39     def create_table(self):
40         query = """
41             CREATE TABLE IF NOT EXISTS reviews_db.reviews (
42                 id UUID,
43                 gostou INT,
44                 usuario_id TEXT,
45                 filme_id TEXT,
46                 comentario TEXT,
47                 criado_em TIMESTAMP,
48                 atualizado_em TIMESTAMP,
49                 PRIMARY KEY (id));
50         """
51         self.__session.execute(query)
```

CREATE

```
80
81 def cria_review(self, review):
82     try:
83         rows = self.__session.execute_async(
84             """
85             INSERT INTO reviews_db.reviews (id, usuario_id, filme_id, comentario, gostou, criado_em, atualizado_em)
86             VALUES (%s, %s, %s, %s, %s, %s, %s)
87             """
88             (
89                 uuid.uuid1(),
90                 review.usuario_id,
91                 review.filme_id,
92                 review.comentario,
93                 review.gostou,
94                 unix_time_millis(datetime.datetime.now()),
95                 unix_time_millis(datetime.datetime.now())
96             ),
97         )
98
99         response = to_dict_list(rows)
100         return {"code": 201, "response": "criado", "count": len(response), "data": response }
101     except Exception as e:
102         return {"code": 500, "response": "erro " + str(e)}
103
```

READ

```
52
53 def listar_reviews(self):
54     try:
55         rows = self.__session.execute_async(
56             "SELECT * FROM reviews_db.reviews",
57         )
58
59         response = to_dict_list(rows)
60
61         return {"code": 200, "response": "ok", "count": len(response), "data": response }
62     except Exception as e:
63         return {"code": 500, "response": "erro "+str(e)}
64
65 def busca_review(self, review_id):
66
67     review_id = uuid.UUID(review_id)
68
69     try:
70         rows = self.__session.execute_async(
71             """
72             SELECT * FROM reviews_db.reviews WHERE id=%s
73             """,
74             [review_id]
75         )
76
77         return {"code": 200, "response": "ok", "data": to_dict_list(rows)}
78     except Exception as e:
79         return {"code": 500, "response": "erro "+str(e)}
80
```

UPDATE

```
122
123     def atualiza_review(self, review_id, novo_review):
124
125         review_id = uuid.UUID(review_id)
126
127         try:
128             rows = self.__session.execute_async(
129                 """
130                 UPDATE reviews_db.reviews
131                 SET comentario = %s,
132                 gostou = %s,
133                 atualizado_em = %s
134                 WHERE id = %s
135                 """,
136                 (novo_review.comentario, novo_review.gostou, unix_time_millis(datetime.datetime.now()), review_id),
137             )
138
139             response = to_dict_list(rows)
140
141             return {"code": 200, "response": "atualizado", "count": len(response), "data": response }
142         except Exception as e:
143             return {"code": 500, "response": "erro"}
```

DELETE

```
103
104     def remove_review(self, review_id):
105
106         review_id = uuid.UUID(review_id)
107
108         try:
109             rows = self.__session.execute_async(
110                 """
111                 DELETE FROM reviews_db.reviews
112                 WHERE id=%s
113                 """,
114                 [review_id],
115             )
116
117             response = to_dict_list(rows)
118
119             return {"code": 200, "response": "removido", "count": len(response), "data": response }
120         except Exception as e:
121             return {"code": 500, "response": "erro"}
```

EXTRA: GET REVIEWS POR FILME

```
145
146     def busca_reviews_filme(self, filme_id):
147
148         try:
149             rows = self.__session.execute_async(
150                 """
151                 SELECT * FROM reviews_db.reviews WHERE filme_id=%s ALLOW FILTERING
152                 """,
153                 [filme_id]
154             )
155
156             return {"code": 200, "response": "ok", "data": to_dict_list(rows)}
157         except Exception as e:
158             return {"code": 500, "response": "erro "+str(e)}
```

VI. VANTAGENS E DESVANTAGENS



VANTAGENS

- **Alta disponibilidade;**
- **Performance;**
- **Tolerante a falhas;**
- **Escalabilidade linear:** se o banco atende 100K de requisições, para atender 200K basta dobrar a infraestrutura;
- Altamente **distribuído**.



DESVANTAGENS

- Se precisar de muita **consistência**, a aplicação terá que garantir;
- Se o volume de dados ou o **throughput** da aplicação for muito pequeno;
- É necessário analisar se o modelo da aplicação suporta o **paradigma** colunar.

V. APLICAÇÕES NOTÁVEIS

APLICAÇÕES NOTÁVEIS



- O **WebEx** da Cisco usa o Cassandra para armazenar feeds e atividades do usuário quase em tempo real;



- O **Discord** mudou para Cassandra para armazenar bilhões de mensagens do MongoDB em novembro de 2015;



- O **Globo.com** usa o Cassandra como um banco de dados de back-end para seus serviços de streaming;

APLICAÇÕES NOTÁVEIS



- A **Netflix** usa Cassandra como seu banco de dados de back-end para seus serviços de streaming;



- O **Uber** usa o Cassandra para armazenar cerca de 10.000 recursos em seu Feature Store atualizado diariamente em toda a empresa para acesso de baixa latência durante previsões de modelos ao vivo;

VI. REFERÊNCIAS

REFERÊNCIAS

- <https://www.devmedia.com.br/introducao-ao-cassandra/38377>
- <https://www.devmedia.com.br/introducao-ao-banco-de-dados-nosql-cassandra/30533>
- <https://medium.com/nstech/apache-cassandra-8250e9f30942>
- <http://db4beginners.com/blog/cassandra/>
- https://pt.wikipedia.org/wiki/Apache_Cassandra
- <https://flask.palletsprojects.com/en/1.1.x/>
- <https://cassandra.apache.org/doc/latest/>
- <https://docs.python.org/3/>
- <https://docs.docker.com/>
- <https://developer.ibm.com/br/technologies/databases/tutorials/ba-set-up-apache-cassandra-architecture/>
- <https://imasters.com.br/banco-de-dados/bancos-de-dados-nosql-uma-visao-geral>
- <https://micreiros.com/tipos-de-bancos-de-dados-nosql/>
- <http://db4beginners.com/blog/escolha-o-tipo-bd/>

DÚVIDAS?



OBRIGADA!



Jayne Moraes



jayne@copin.ufcg.edu.br

"Feliz daquele que consegue enxergar na alegria do outro como resultado das suas ações, do seu investimento, da sua dedicação e do seu empenho."

Clóvis de Barros Filho

Cassandra Database

No-SQL



Jayne de Moraes Silva
Programa de Pós-Graduação em Ciência da Computação (Mestrado)
Disciplina: Banco de Dados - Prof. Dr. Carlos Eduardo
Novembro, 2020